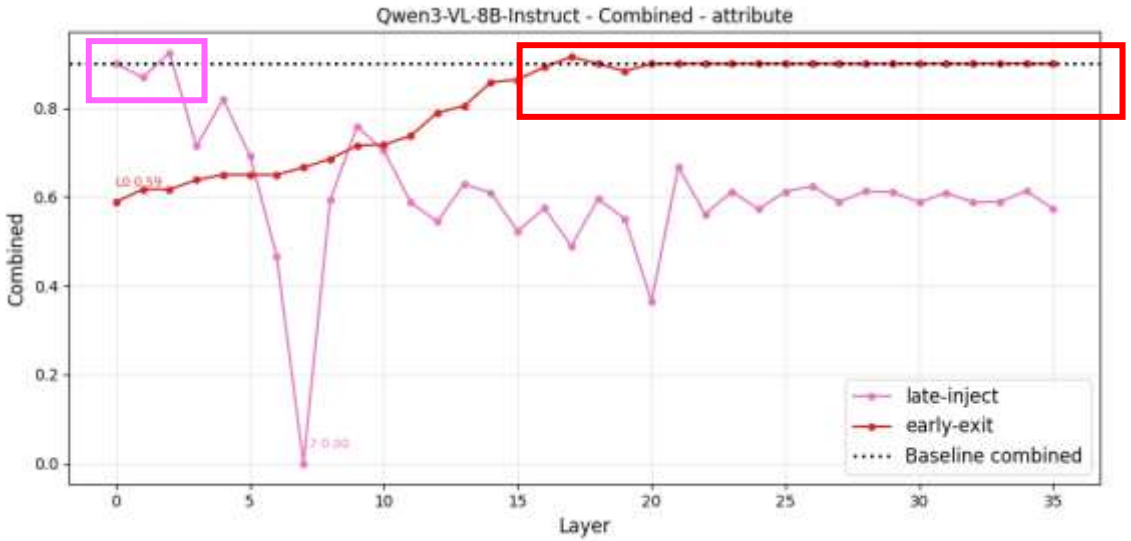
中国科学院自动化研究所
Institute of Automation, Chinese Academy of Sciences

架构设计 —— 多模态推理架构降冗

目标：裁剪模型层间计算的结构性冗余，在保留核心推理能力的前提下，实现轻量化推理架构。

Dual-knockout 探测

早退（红色曲线）：浅层位置提前丢弃视觉 token 信息。
晚注入（粉色曲线）：延迟注入视觉 token 信息。



早退 L16 即恢复基准，晚注入跳过浅层（L0-2）仍保持性能；Dual-Knockout 双向探测揭示**多模态时序融合存在显著架构冗余。**

多模态注意力的关键阶段

多模态注意力机制：逐层探测 query 与图像区域间注意力分布的时序演化与空间聚焦。

36 层 attention 可视化显示，跨模态推理仅集中在 L19–L25 少数中间层，浅层分散、深层扩散，**两端存在显著注意力冗余。**

